

# AI 使用说明情况

## 一、使用工具与模型

工具：ChatGPT 和 Codex

模型：GPT-6 Astra、GPT-5.6 Sol

## 二、AI提示词

从发布挑战前到完成挑战后的提示词：

- 1、“给我讲讲你刚才说的那些提前要会的prefill decode啥的 vllm sglang是什么我都不知知道，一点都没听说过，高性能体现在哪.....理解了。kernels不知道.....SGLang我还不明白他的优势和vllm的不同”
- 2、“你现在是我的老师，只指导我做，告诉我原理和为什么，讲清楚命令、操作细节。”
- 3、“uv是什么工具，用来干嘛的，为什么要用uv pip装sglang”
- 4、“trace的jsonl已经给了timestamp，为什么还要用poisson到达过程生成请求时间”
- 5、“如果一个 workload 的所有请求都没有公共前缀，paged attention 还有用吗，radix attention 呢？”
- 6、“两个请求中出现完全相同的一段文本，为什么不一定能复用这段文本的 kv cache”
- 7、“我看我这次发的25个请求也看不出来哪里有性能提升啊，为什么说radix attention和kv cache带来了性能提升，如果没有会很慢吗。高性能在哪”

## 三、AI 如何帮助我学习

环境搭建阶段，AI 提供安装环境步骤和命令，不用一边看官方操作文档然后一边改命令，比如，帮我协助定位 nvcc 缺失。过程中会有官方文档完全没有的意外发生，环境装一半C盘空间不足，需要将整个ubuntu环境和已经安装好的sglang服务迁移到G盘，直接问AI跟着操作就可以解决了。也让我对WSL和ubuntu系统有了更深的了解。

实验阶段，任务发布前我先让AI 解释 Prefill、Decode、KV Cache、tokenizer、vllm、SGLang等专业名词和整个AI System是如何运作的。实验过程中一边做一边询问AI异步并发、TTFT、命令含义、解释代码等。AI提供采样、构造 synthetic prompt、发送 workload 和单次推理的代码示例。主要实验脚本参考 AI 给出的代码，由我在终端保存、运行、检查结果和截图。

看论文阶段，翻译论文，让AI先告诉我论文重点再去对重点精读，深度理解论文中的RadixAttention/RadixCache、KV cache、PagedAttention的作用和实现。

AI误导方面。第一、在我准备迁移ubuntu系统到G盘时，AI 对 C 盘剩余空间的建议曾前后变化，一会儿叫我直接ctrl+c停止装SGLang，一会儿又说装完再迁移。我自己先手动清了C盘装完SGLang后再迁移。第二、把关闭 Prefill CUDA Graph 的排障方案说得过于负面。关闭优化会改变性能条件，但也不是一定不能完成实验。我决定修复一下nvcc CUDA Toolkit后再启动SGLang推理服务。AI在环境配置、启动服务、编写代码方面基本没有出错。

综上：AI对这次挑战起了辅助和指导作用，没有用agent直全程AI操作部署完成挑战，全程我自己执行，对于不懂的先了解再输入命令、代码，不懂的概念先问再操作。仅参考AI建议，边完成挑战边学习陌生知识。