

第一次挑战作业感受

一、我是怎样完成这次挑战的

我以前在AWS服务器上部署过接claude api的chatbot的服务，我知道用python调用大模型API发请求，但在此之前从未听说过“推理优化”这件事，并不了解大模型推理的完整过程，一开始我把SGLang 和 vLLM 理解成部署模型后再加上的优化工具。（图1）在AI的纠正下，知道了vLLM 和 SGLang 本身就是两套高性能的大模型推理框架（其实当时还是不是很理解）。这次在 Windows 的 WSL2 Ubuntu 中运行 SGLang 0.5.14 和 Qwen3-0.6B，才逐渐把模型、推理框架、GPU 和 HTTP 客户端的关系对应起来。




图1 任务发布前对vLLM和SGLang的理解

我的操作按群里发的pdf推进：先装了WSL、ubuntu，然后就是我之前熟悉的linux操作，创建项目文件夹、装Ubuntu环境、配虚拟环境再激活……下载SGLang、Ray，千问。不知道是不是挂了代理的原因，SGLang下了很久。期间还遇到C盘爆了迁移的意外、找不到CUDA Graph和nvcc，这都是借助AI解决。（图2）




图2：找不到CUDA Graph和nvcc

运行前检查 Linux 和 GPU，再安装环境、启动服务，完成单次请求后才做 workload。单次请求很简单，curl命令中给出的openAI格式的json和我之前部署chatbot发message的格式几乎完全一样，没想到之前的经验会在这里用上。但是到了workload部分，就变得陌生，我之前从未处理过并发、异步的问题，还有对于mooncake trace只给input_token output_token不给具体文字感到疑惑，一开始还以为我要自己去凑500 1000token（图3），询问AI后知道是通过模型的tokenizer去切分，给超额input，tokenizer自己encode/decode，最后只截取len(input_token)，也不需要token有语义，之后用了AI的代码完成了synthe prompt之后用于给千问发请求。考虑到我电脑只有6G显存，所以我对mooncake提供的样例做了筛选，避免过大input_token和output_token导致显存不够。




图3：构造synthetic prompt过程的困惑

过程中AI天生喜欢用命令行直接写python程序，但我感觉不方便后来维护和多次实验，所以我把筛选样例、synthetic_prompt、run_workload、single_request分别写成四个python脚本放在scripts/下，然后再用命令运行。25 条样本经过分词验证后，以平均每秒 2 个请求的泊松到达过程并发发送，记录实际输入输出 token 数、状态、TTFT 和 latency，最终得到 25/25 成功的结果，并保存两张截图。

二、最困难的地方及解决过程

我觉得最困难的是判断程序究竟卡在哪一层。一次启动时模型权重已经加载，服务却在Prefill CUDA Graph 相关初始化路径报错，提示找不到 nvcc。当时我还在问是不是下载没有完成（图4）。经过检查才知道，驱动和 PyTorch 能使用 GPU，并不意味着 CUDA 编译工具也已齐全。补装 CUDA Toolkit 13.0、修正环境变量的生效顺序后，服务才成功启动。

磁盘空间也是一个意外。Ubuntu 内安装的大量依赖实际占用了 C 盘的 WSL 虚拟硬盘。我清理空间后，根据 AI 指导将整个 Ubuntu 迁移到 G 盘，并在迁移后验证环境。这让我开始注意安装位置、缓存和存储空间，而不只是软件版本。

理解实验方法也花了不少时间。我追问过为什么 trace 没有原始文本、为什么需要 tokenizer、为什么不能发送一条等结束再发下一条。后来我明确要求区分目标输出量和服务实际统计的输出量，避免把请求参数直接当成实验结果。相比照着运行，我更希望每个字段和步骤都能解释清楚。

最后阅读论文也是困难。实际操作对于原理不需要深入研究就能干，甚至跟着AI和操作文档按部就班即可完成两张截图，甚至可以agent自动完成。但是真正决定是否理解框架还是要看论文，AI直接问答都是碎片化的知识，AI还爱类比举例，诚然降低了知识的理解难度，但是对背后原理就不够深刻。无法串联起来，光知道RadixAttention KV Cache等机制，但是缺少论文中的严谨论



图4：误以为是模型没下载好

证，没有自己画一遍流程图和对着论文的radix tree理解，就不知道为什么SGLang/vllm框架可以加速推理。看论文最难是英语，里面很对领域专业词汇没见过只能借助AI翻译、划词翻译，AI解释。虽然很难，但是我觉得看论文是不可或缺的一步。

三、对后续科研工作的启发

这次经历让我认识到，从零开展研究需要先明确问题和验收标准，再查资料建立机制理解，可以先阅读论文，再复现实验。这次我采用的是先一边做实验一边理解原理，最后再去看论文复盘和深入理解。下次可以先看看论文，再实验可能会有更好的效果。搭建可运行的最小实验（比如这次的单次请求）并留下足够的复现记录。遇到失败时，应根据日志和分层检查缩小范围，每次修改后再验证，避免把所有问题都归结为“环境没装好”。合理使用AI，科研工作严谨的，AI不能代替人工审查和思考，再聪明的AI也会犯错和误导，必须人工核验，独立思考，实事求是。

我也开始区分“跑通实验”和“验证结论”。这次 workload 说明服务可以处理这组请求，但随机 prompt 没有复现原 trace 的前缀共享关系，25 条记录也不足以证明某项优化带来了多少提升。（图5）以后若研究前缀复用，我会固定模型和长度，控制公共前缀比例，安排有无缓存的对照和重复测量，再解释性能差异。




图5：对本次实验无法对比得出性能差异的疑惑