

操作保存

截图 1：单次推理请求



截图 2：Mooncake 采样 workload

